

فرم تعریف پروژه

فارغ التحصیلی دوره کارشناسی

تاریخ:

شماره:

عنوان پروژه: طراحی سامانه‌ی تشخیص ضایعه دنتی جروس از عکس‌های رادیوگرافی با استفاده از روش‌های یادگیری عمیق	
استاد راهنمای پروژه: دکتر حامد فربه	امضاء:
مشخصات دانشجو:	
نام و نام خانوادگی: رضا توسلی ^۱ - آریا وارسته‌نژاد ^۲	گرایش: مهندسی کامپیوتر
شماره دانشجویی: ۹۵۳۱۴۳۵ - ۹۵۳۱۰۱۹	ترم ثبت نام پروژه: دوم ۹۸-۹۹
داور پروژه: دکتر محمد رحمتی	امضاء داور:
مشاور پروژه: دکتر سینا وارسته‌نژاد	امضاء مشاور:
<p>شرح پروژه (در صورت مشترک بودن بخشی از کار که بعهدہ دانشجو می باشد مشخص شود):</p> <p>تصاویر پزشکی از مهم‌ترین المان‌های در دسترس پزشکان برای تشخیص وجود یا عدم وجود بیماری و تشخیص شدت بیماری هستند. پردازش این تصاویر از این جهت در علم پزشکی بسیار پراهمیت است که می‌تواند دقت تشخیص را بالاتر ببرد و به پزشک برای امکان ارائه طرح بهینه درمان کمک کند. پزشکان از روش‌های گوناگونی با توجه به هدف خود و قابلیت‌های تصویربرداری استفاده می‌کنند. توانمندی و قدرت بالای معماری شبکه‌های عصبی عمیق ما را تشویق می‌کند که از آن‌ها برای تحلیل تصاویر پزشکی استفاده نماییم. در میان ساختارهای عمیق، به دلیل موفقیت‌های اخیر شبکه‌های عصبی کانولوشنی^۳، بر روی این ساختارها متمرکز می‌شویم. در این پروژه، مطالعات بر روی تصاویر رادیوگرافی دندانانی انجام خواهد شد و از طبقه‌بندی‌کننده شبکه‌ی عصبی عمیق به کمک کتابخانه‌های تنسرفلو^۴ و کراس^۵ استفاده خواهد شد. مجموعه‌ی داده‌های عکس‌های رادیولوژی با توجه به تعداد داده‌های گردآوری شده به سه دسته آموزش، توسعه و آزمون تقسیم شده و مورد استفاده قرار می‌گیرند و برای ارزیابی نتایج حاصل شده از دقت^۶، صحت^۷، بازیابی^۸ و حساسیت^۹ به همراه معیار F1^{۱۰} استفاده خواهد شد.</p> <p>در این پروژه بخش‌های گردآوری مجموعه‌ی داده، پیش‌پردازش تصاویر، داده‌افزایی، جستجوی معماری‌های شبکه عصبی، آموزش شبکه عصبی و تحلیل و ارائه نتایج به کمک نرم افزار SPSS بر عهده آریا وارسته‌نژاد و جستجوی معماری‌های شبکه عصبی، بررسی معماری‌های حاصل از جستجو، انتخاب معماری مناسب، آموزش شبکه عصبی، طراحی و پیاده‌سازی برنامه وب و طراحی و پیاده‌سازی برنامه موبایل برای سیستم‌عامل‌های Android و iOS برعهده رضا توسلی خواهد بود.</p>	
وسائل مورد نیاز:	
<ul style="list-style-type: none"> دسترسی به کامپیوتر متصل به اینترنت دسترسی به سیستم مناسب برای آموزش شبکه عصبی امکان دسترسی به مقالات مرتبط همکاری مراکز تصویر برداری برای جمع‌آوری مجموعه‌ی داده 	
محل انجام پروژه: دانشکده مهندسی کامپیوتر دانشگاه صنعتی امیرکبیر	تاریخ شروع: تیرماه ۱۳۹۹
تاریخ تحویل به آموزش دانشکده:	
تاریخ تصویب در گروه:	اسم و امضاء:
تاریخ تصویب در دانشکده:	اسم و امضاء:
اصلاحات لازم در تعریف پروژه:	

¹ rezatavasoli@aut.ac.ir

² a.varaste.n@gmail.com

³ Convolutional Neural Network

⁴ Tensorflow

⁵ Keras

⁶ Precision

⁷ Accuracy

⁸ Recall

⁹ Specificity

¹⁰ F1 score

۱- مقدمه


مجموعه‌ی کنونی سامانه‌های هوش مصنوعی، انقلاب فناورانه گسترده‌ای را با خود به ارمغان آورده است. انقلابی که یکی از بازیگران مهم آن یادگیری عمیق است. این تغییرات می‌توانند شیوه‌های فعلی تشخیص در پزشکی را تغییر دهند و آن‌ها را به سمت تشخیص‌های دقیق‌تر، سریع‌تر و قابل اعتمادتر هدایت کنند. در سطح حرفه‌ای، پزشکان نیازمند توسعه تحقیقات و همکاری‌های بین رشته‌ای برای دستیابی به سیستم‌های یادگیری بر اساس هوش مصنوعی هستند.

تصاویر پزشکی از مهمترین المان‌های در دسترس پزشکان برای تشخیص وجود یا عدم وجود بیماری و تعیین شدت آن هستند. پردازش این تصاویر از آن جهت در علم پزشکی مهم است که می‌تواند دقت تشخیص را بالاتر ببرد و به پزشک برای امکان ارائه طرح بهینه‌ی درمان کمک کند. پزشکان از روش‌های گوناگونی با توجه به هدف خود و قابلیت‌های انواع تصویربرداری استفاده می‌کنند. روش‌های تصویربرداری در حالت کلی به دو گروه ساختاری و عملکردی تقسیم می‌شوند. روش‌های ساختاری روش‌هایی هستند که آناتومی ارگان‌های بدن را مشخص می‌کنند. روش‌های عملکردی، روش‌هایی هستند که ارتباطی به ساختار ارگان‌ها و اعضای بدن ندارند بلکه میزان عملکرد ارگان مورد نظر و فیزیولوژی آن را بررسی می‌کنند. از روش‌های مشهور ساختاری می‌توان به سی‌تی‌اسکن^۱ و ام‌آر‌آی^۲ اشاره کرد. پردازش تصاویر پزشکی به پزشک کمک می‌کند که دقت تشخیص را بالاتر ببرد و در حقیقت پزشک می‌تواند از خروجی این پردازش تصاویر به عنوان دستیار خود استفاده کند [۶].

پردازش تصاویر پزشکی که توسط متخصصان پردازش تصویر انجام می‌شود نیاز به صرف زمان و انرژی زیادی برای استخراج ویژگی‌های تصاویر دارد. برای کاهش مشکل استخراج ویژگی از داده‌های ورودی، نسل جدید الگوریتم‌های یادگیری ماشین که به عنوان الگوریتم‌های یادگیری عمیق شناخته می‌شوند تلاش می‌کنند استخراج ویژگی در فرآیند آموزش و توسط خود الگوریتم صورت پذیرد. این نکته بسیار مهم و همچنین دقت بالای این شبکه‌ها در بسیاری از وظیفه‌هایی که قبلاً توسط الگوریتم‌های معمولی یادگیری ماشین انجام شده بود، باعث شد که از سال ۲۰۱۲ به بعد این حوزه با سرعتی چشمگیر رشد کند [۶]. آنچه فناوری هوش مصنوعی را از فناوری‌های قدیمی در مسائل مرتبط با سلامت متمایز می‌کند، توانایی کسب اطلاعات، پردازش آن و ارائه خروجی دقیق به کاربر نهایی است. هوش مصنوعی این عملیات را با استفاده از الگوریتم‌هایی مانند یادگیری عمیق انجام می‌دهد که می‌توانند الگوها را در تصاویر تشخیص دهند.

۲- ضایعه سیستم دنتی جروس

سیست دنتی جروس^۳، دومین سیست شایع فکین است که دور تاج دندان رویش نیافته یا اضافی شکل می‌گیرد و محل آن دقیقاً بالای تاج دندان درگیر است [۷]. این نوع از سیست می‌تواند در ارتباط با هر دندان رویش نیافته‌ای در فک رخ دهد اما، معمولاً دندان‌های خلف فک پایین را درگیر می‌کند (مطابق شکل ۱) [۸]. در نتیجه اهمیت بررسی ادواری دندان‌های عقل نهفته باید بیشتر مورد توجه قرار گیرد. اگرچه این سیست ممکن است در یک دامنه وسیع سنی مشاهده شود، اما اغلب در بیماران بین ۱۰ تا ۳۰ سال شیوع بیشتری دارد.



شکل ۱: محل قرارگیری کسیت دنتی جروس و شکل کلی آن [۸]

^۱ CT Scan

^۲ MRI

^۳ Dentigerous cyst

سیست‌های دنتی جروس کوچک معمولاً بدون علامت هستند و تنها در آزمایش‌های رادیوگرافی و یا زمانی که برای تعیین علت عدم رویش دندان عکس‌برداری می‌شود، کشف می‌شوند. این سیست قادر به رشد با اندازه قابل توجهی است و سیست‌های بزرگتر ممکن است در ارتباط با یک تورم استخوانی بدون درد در ناحیه درگیر باشند. ضایعات وسیع از این نوع در نهایت می‌توانند باعث عدم تقارن در صورت شوند. یک نکته تشخیصی با اهمیت این است که این سیست در محل اتصال مینا به ریشه شکل می‌گیرد. از عوارض مهم و قابل ذکر این ضایعه تمایل به جابجایی و تحلیل دندان‌های مجاور است [۷].

حدود و شکل: سیست دنتی جروس معمولاً دارای محدوده‌ای با حدود مشخص و حدود خارجی انحنادار یا گرد می‌باشد و به لحاظ ظاهری سه دسته کلی مطابق شکل ۲ دارند [۱] و در نمای داخلی بجز ناحیه تاج دندان درگیر کاملاً رادیولوسنت^۲ (وجود نمای تیره در عکس رادیوگرافیک) است [۷].

RADIOLOGICAL FEATURES

• CENTRAL TYPE:



• LATERAL TYPE :



• CIRCUMFERENTIAL TYPE :



شکل ۲: اشکال حالت‌های مختلف ضایعه دنتی جروس [۱]

روش‌های تشخیص: تشخیص براساس مشاهده اتصال سیست به مرز مینا و ریشه دندان به دو روش تهاجمی (جراحی) و غیرتهاجمی (عکس رادیوگرافی) صورت می‌گیرد (شکل ۳) و خطرات، هزینه‌ها و عوارض ناشی از روش جراحی باعث ایجاد تمایل برای تشخیص با روش عکس‌برداری می‌شود [۷].



شکل ۳: نمای رادیوگرافی از ضایعه دنتی جروس [۲]


¹ Cortex

² Radiolucent

۳- یادگیری عمیق

یادگیری عمیق، تشخیص الگو و یادگیری ماشین را متحول ساخته است. اصطلاح یادگیری عمیق اولین بار به ماشین یادگیری دکارت و شبکه‌های عصبی مصنوعی اطلاق شد. در یادگیری عمیق، ویژگی‌های غیرخطی در چندین لایه استخراج می‌شوند و به یک دسته‌بندی‌کننده^۱ داده می‌شوند تا یک پیش‌بینی انجام شود. یکی از مواردی که ما را به استفاده از تعداد لایه‌های بیشتر در یادگیری عمیق ترغیب می‌کند استخراج ویژگی‌های بیشتر است.

الگوریتم‌های یادگیری عمیق بیشتر در بستر شبکه‌های عصبی مصنوعی توسعه یافته‌اند. در شبکه‌های عصبی معمولی، تعداد لایه‌های مخفی معمولاً بیشتر از دو لایه نیست. به همین سبب به این شبکه‌ها، کم‌عمق گفته می‌شود. در مقابل وقتی که تعداد لایه‌های مخفی افزایش می‌یابد این شبکه‌ها را شبکه‌های عمیق نام می‌دهند [۶]. نمایی از ورودی، محاسبات و خروجی داخل یک گره از لایه‌های مخفی شبکه عصبی در شکل ۴ نشان داده شده است.



شکل ۴: نمایی از ورودی، محاسبات و خروجی داخل یک گره از لایه‌های مخفی شبکه عصبی [۳]

۴- شبکه عصبی کانولوشنی

در سال‌های اخیر روش‌های جدیدی برای تشخیص و طبقه‌بندی تصاویر پزشکی بدون نیاز به استخراج ویژگی‌ها به صورت دستی، مبتنی بر شبکه‌های عصبی کانولوشنی ارائه شده‌اند که نسبت به شبکه‌های عصبی معمولی به علت داشتن لایه‌های کانولوشن و مخفی بیشتر در زمینه کار با ورودی با ابعاد بالاتر مانند تصاویر دارای توانمندی بیشتری هستند.


برای پیاده‌سازی شبکه‌های عصبی عمیق از جمله شبکه کانولوشنی معمولاً به مجموعه‌ی داده^۲ عظیمی نیاز است. در پردازش تصاویر پزشکی مجموعه‌ی داده بزرگ به ندرت یافت می‌شود و نکته دیگر اینکه زمان اجرا هم طولانی است. بدین منظور شبکه‌هایی با لایه‌های زیاد از قبل آموزش داده شده‌اند و برای این مساله خاص با مجموعه‌ی داده کوچکتر و ایجاد تغییرات کوچکی در معماری مخصوصاً لایه آخر، مسئله خود را حل می‌کنیم.

برخی از تحقیقاتی که روی طبقه‌بندی تصاویر پزشکی با استفاده از شبکه عصبی کانولوشنی انجام شده‌است، توانسته‌اند کارایی بهتری نسبت به تشخیص متخصصان این حوزه داشته باشند. سامانه ChexNet^۳ که معماری آن در شکل ۵ قابل مشاهده است، یک شبکه عصبی کانولوشنی با ۱۲۱ لایه است و با مجموعه‌ی داده‌ای با بیش از ۱۰۰۰۰ تصویر Xray قفسه سینه تمرین داده شده است [۹] توانسته میانگین کارایی بهتری نسبت به رادیولوژیست‌ها داشته باشد.

¹ Classifier

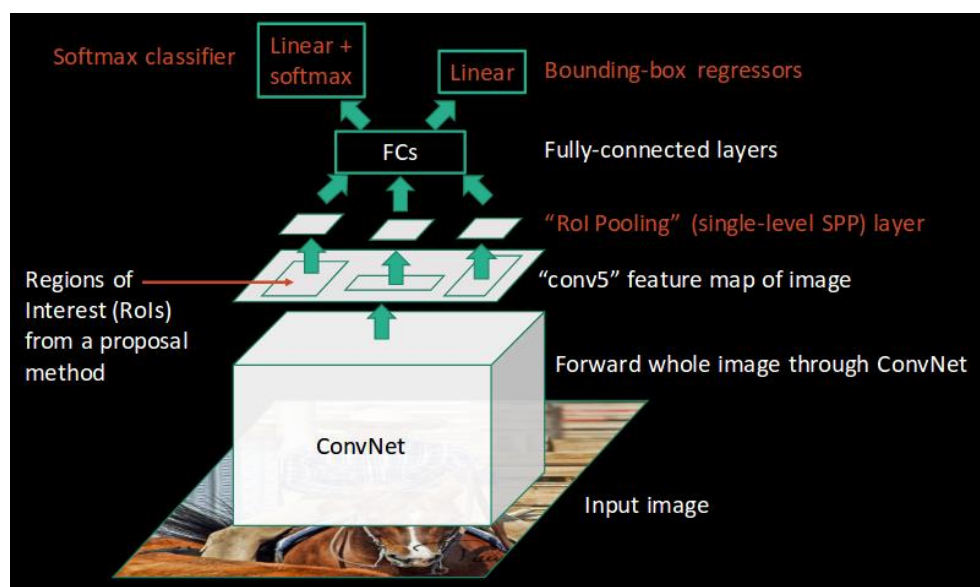
² Dataset

³ <https://stanfordmlgroup.github.io/projects/chexnet/>



شکل ۵: معماری شبکه ChexNet [۹]

یکی از شبکه‌های عصبی کانولوشنی که برای پردازش تصویر پزشکی و به خصوص تصاویر دندان استفاده می‌شود، Faster R-CNN است. Faster R-CNN یک نسخه تغییر یافته از Fast R-CNN است. در Fast R-CNN عکسی که به عنوان ورودی داده می‌شود، به یک ConvNet فرستاده می‌شود تا ناحیه‌های مطلوب^۱ تولید شوند. سپس یک لایه ادغام^۲ روی تمامی این ناحیه‌ها اعمال می‌شود تا آن‌ها را هم‌شکل کند. سپس هر ناحیه به شبکه کاملاً همبند داده می‌شود. یک لایه Softmax بالای شبکه کاملاً همبند قرار داده می‌شود تا کلاس‌های خروجی را تولید کند. همراه با این لایه، یک لایه رگرسیون خطی نیز بصورت موازی استفاده می‌شود تا مختصات کادرهای محدودکننده^۳ را در کلاس‌های پیش‌بینی شده نشان دهد. معماری Fast R-CNN در شکل ۶ نشان داده است [۱۰].



شکل ۶: معماری Fast R-CNN [۴]

در Fast R-CNN برای انتخاب مناطق مطلوب از الگوریتم جستجوی انتخابی استفاده می‌شود که سرعت پایینی دارد. برای حل این مشکل در Faster R-CNN از شبکه پیشنهاد ناحیه کاندید (RPN)^۴ استفاده می‌شود. RPN بر نقشه‌های ویژگی^۵ اعمال می‌شود و یک امتیاز را برای هر ناحیه مشخص می‌کند. نقشه ویژگی خروجی است که از ConvNet بعد از وارد کردن تصویر ورودی، دریافت می‌شود. یک لایه ادغام ROI بر این پیشنهادها اعمال می‌شود تا اندازه آن‌ها را یکسان کند. در آخر این پیشنهادها به یک شبکه کاملاً همبند فرستاده می‌شوند تا کلاس‌بندی انجام شود. معماری Faster R-CNN در شکل ۷ نشان داده شده است [۱۰].


^۱ ROI

^۲ Pooling Layer

^۳ Bounding Box

^۴ Regional Proposal Network

^۵ Feature Maps

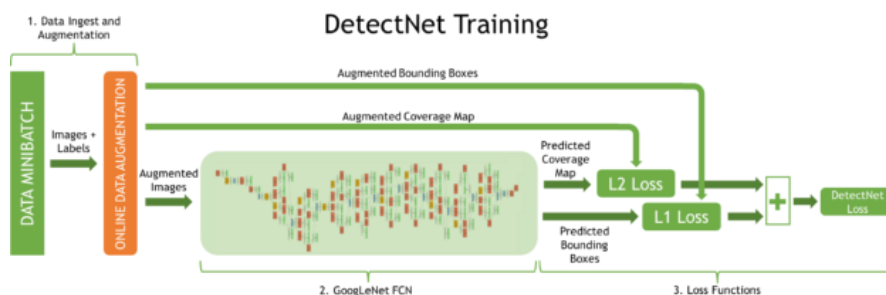


شکل ۷: معماری Faster R-CNN [۴]

شبکه عصبی کانولوشنی دیگری که برای پردازش تصاویر دندان استفاده می‌شود، شبکه عصبی DetectNet است. DetectNet یک شبکه عصبی عمیق است که برای شناسایی اشیاء، توسط شرکت NVIDIA توسعه داده شده است. این شبکه عصبی عمیق دارای ۵ بخش است.

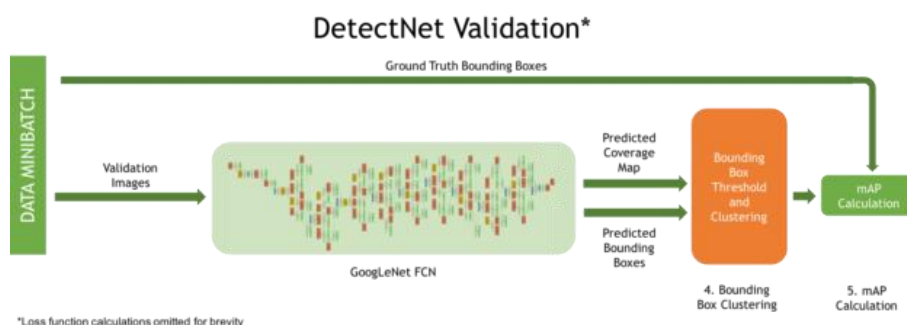
- (۱) وارد کردن داده‌ها و اضافه کردن افزونگی به آن‌ها
- (۲) یک شبکه کاملاً کانولوشنی (fully-convolutional network)
- (۳) اندازه‌گیری تابع زیان (Loss function)
- (۴) تابع خوشه‌بندی (clustering function) که نتیجه پیش‌بینی را نشان می‌دهد.
- (۵) محاسبه‌ی Mean Average Precision

در این معماری، لایه‌ای از شبکه^۱ روی تصویر قرار داده می‌شود که اندازه‌ی خانه‌های این شبکه را کمی کوچکتر از کوچکترین شی‌ای که می‌خواهیم شناسایی کنیم، قرار می‌دهیم. هر خانه شبکه با دو برچسب مشخص می‌شود. برچسب اول نوع کلاس شی‌ای که داخل خانه وجود دارد را مشخص می‌کند و برچسب دوم مختصات این خانه را نسبت به مرکز شبکه بیان می‌کند. بعد از آموزش، این شبکه باید وجود یا عدم وجود شی در هر خانه شبکه را پیش‌بینی کند و مختصات آن خانه را برگرداند. در شکل ۸ ساختار DetectNet برای مرحله‌ی آموزش و در شکل ۹ ساختار برای مرحله‌ی ارزیابی نشان داده شده است [۵].



شکل ۸: ساختار DetectNet برای آموزش [۵]

^۱ grid



شکل ۹: ساختار DetectNet برای ارزیابی [۵]

۵- سوابق موضوع

در سال ۲۰۱۸ Jae-Hong و همکارانش روی تشخیص پوسیدگی‌های دندان با مدل یادگیری عمیق با استفاده از شبکه‌های عصبی کانولوشنی روشی ارائه دادند [۱۱]. برای این پژوهش ۳۰۰۰ تصویر رادیوگرافی گردآوری شد که از ۲۴۰۰ تصویر برای آموزش شبکه عصبی و از ۶۰۰ تصویر برای آزمون استفاده شد. برای پیش‌پردازش و یادگیری انتقالی، شبکه عصبی inception v3 مورد استفاده قرار گرفت. برای ارزیابی این پژوهش، معیارهای حساسیت، دقت و صحت محاسبه شد که این شبکه عصبی توانست با دقت ۸۹٪ پوسیدگی دندان را تشخیص دهد. Imangaliyev و همکارانش در سال ۲۰۱۶ تحقیقاتی برای دسته‌بندی پلاک‌های دندان با روش‌های یادگیری عمیق به کمک تصاویر انجام دادند در این مقاله یک مدل طبقه‌بندی تصویر مبتنی بر شبکه عصبی کانولوشنی برای تصاویر فلورسانس نوری کمی ناشی از نور استفاده می‌شود [۱۲]. Jae-Hong به همراه همکاران خود تحقیقاتی با هدف توسعه یک سیستم تشخیص کامپیوتری براساس یادگیری عمیق با شبکه‌های عصبی کانولوشنی به منظور ارزیابی سودمندی و دقت این سیستم‌ها و آشنایی با توانایی‌هایی این روش‌ها در جهت تشخیص دندان‌هایی که در معرض خطر قرار دارند در سال ۲۰۱۸ انجام داد. در این پژوهش محققان از شبکه‌های از پیش تعلیم داده‌شده استفاده کردند. مجموعه‌ی داده‌های مورد استفاده خود را به سه دسته با اندازه‌های ۱۰۴۴ برای تمرین، ۳۴۸ برای اعتبارسنجی و ۳۴۸ مورد برای آزمون تقسیم کردند. دقت بدست آمده در این سامانه برابر با ۷۳.۴٪ بود [۱۳].

۶- طرح پیشنهادی

توانمندی و قدرت بالای معماری شبکه‌های عصبی عمیق ما را تشویق می‌کند که از این معماری‌ها برای تحلیل تصاویر پزشکی استفاده نماییم. در میان ساختارهای عمیق، به دلیل موفقیت‌های اخیر شبکه‌های عصبی کانولوشنی^۱، بر روی این ساختارها متمرکز می‌شویم. در این پروژه پس از جمع‌آوری داده‌ها، آن‌ها را به سه دسته‌ی آموزش، آزمایش و توسعه تقسیم می‌کنیم. این داده‌ها توسط مشاور برچسب‌گذاری می‌شوند. برای نشانه‌گذاری عکس از نرم‌افزار LabelImg استفاده می‌شود. بعد از پیش‌پردازش عکس‌ها، آن‌ها به عنوان ورودی به شبکه عصبی کانولوشنی داده می‌شوند تا در یک طبقه‌بندی دودویی نوع کلاس خروجی عکس که نشان‌دهنده‌ی وجود یا عدم وجود ضایعه دنتی‌جروس است، مشخص گردد. برای این کار چندین معماری شبکه عصبی کانولوشنی بررسی می‌شوند و با تغییر و بروزرسانی ابرپارامترها در فریمورک تنسرفلو^۲، با استفاده از نتایج حاصل از معیارهای ارزیابی، بهترین معماری برای این طبقه‌بندی انتخاب می‌شود.

برای پیاده‌سازی از زبان پایتون^۳ و فریمورک‌های تنسرفلو و کراس^۱ استفاده خواهد شد. برای محیط پیاده‌سازی از Google Colab استفاده خواهد شد. این محیط برای مراحل آموزش و آزمون، سخت‌افزار واحد پردازش گرافیکی^۲ و واحد پردازش مرکزی^۳ رایگان بر بستر ابر ارائه می‌دهد و بصورت پیش‌فرض قابلیت استفاده از فریمورک‌های ذکر شده را دارا است.

¹ Convolutional Neural Network

² Tensorflow

³ Python

۶-۱- جمع‌آوری مجموعه‌ی داده

یادگیری عمیق نیاز به تعداد زیادی مجموعه‌ی داده آموزشی دارد. دقت طبقه‌بندی‌کننده یادگیری عمیق تا حد زیادی به کیفیت و اندازه مجموعه‌ی داده بستگی دارد. در دسترس نبودن مجموعه‌ی داده یکی از بزرگترین موانع برای موفقیت یادگیری عمیق در تصویربرداری پزشکی است. از طرف دیگر، توسعه یک مجموعه‌ی داده، کاری بسیار زمان‌بر است. برای جمع‌آوری مجموعه‌ی داده با همکاری مشاور با مراجعه حضوری به دانشکده‌های دندان‌پزشکی، درمانگاه‌ها، مطب‌های خصوصی و مراکز رادیولوژی تلاش می‌شود مجموعه‌ی داده هرچه بزرگ‌تری را گردآوری کرد. پس از آن برای برچسب‌گذاری از همکاری متخصصان دندانپزشکی و رادیولوژی استفاده خواهد شد. برای کمک به معضل اندازه‌ی مجموعه‌ی داده از روش‌های داده‌افزایی^۴ مانند: قرینه‌سازی^۵، چرخش^۶ و تغییر مقیاس^۷ که برای افزایش کارایی مجموعه‌ی داده‌ی کوچک مفید هستند، استفاده می‌کنیم.

۶-۲- پیش‌پردازش

استفاده از روش‌های پردازش تصویر در سال‌های اخیر به سرعت افزایش یافته است. امروزه، ثبت و ذخیره‌سازی تصاویر پزشکی به‌صورت دیجیتالی انجام می‌شود. اما تفسیر جزئیات تصاویر پزشکی همچنان زمان‌بر است. چالش‌هایی که در این رابطه وجود دارند تفاوت در کنتراست^۸، روشنایی، درخشندگی^۹ و سایر ویژگی‌های عکس‌های مجموعه‌ی داده که ناشی از تفاوت‌هایی است که دستگاه‌های عکس‌برداری در مراکز گوناگون دارند و وجود نویز در تصاویر و یکسان نبودن اندازه عکس‌های مجموعه‌ی داده است. به همین جهت پیش از استفاده از داده‌های ورودی به شبکه عصبی با استفاده از پردازش تصویر ویژگی‌هایی که در بالا ذکر شد و مواردی مانند اندازه و رزولوشن عکس‌ها یک‌دست می‌شود، نویز موجود در تصاویر گرفته می‌شود و تنظیم و یک‌دست‌سازی زوایا انجام می‌شود تا بهره‌وری بالاتری بدست آوریم. در همین راستا برای پیش‌پردازش از کتابخانه OpenCV استفاده خواهد شد.

۶-۳- آموزش دادن شبکه عصبی

در مرحله آموزش، تصاویر آموزشی به همراه کلاس خروجی آن برای شبکه در نظر گرفته می‌شود. حین آموزش وزن‌های فیلتر در هر تکرار به‌روز می‌شوند. به نحوی که بعد از چندین تکرار وزن‌های بهینه به‌روز می‌شوند و شبکه آموزش می‌بیند تا بهترین ویژگی را از تصاویر استخراج کند. پس از آموزش، وزن‌های بهینه برای مرحله طبقه‌بندی و تست مورد استفاده قرار می‌گیرند. شبکه عصبی در لایه‌ی ورودی، یک تصویر یا بخشی از تصویر پزشکی دندان‌ها را دریافت می‌کند. سپس در چندین لایه پنهانی که کار آن‌ها استخراج ویژگی از تصویر است، به هر یک از جنبه‌های موجود در تصویر متناسب با میزان اهمیت آن‌ها، وزن‌های قابل یادگیری و سوگیری^{۱۰} تخصیص داده می‌شود. در لایه‌ی خروجی، پاسخ شبکه‌ی عصبی به ورودی داده شده، نمایش داده می‌شود. هر گره در شبکه‌ی عصبی تعدادی ورودی دریافت کرده و سپس حاصل ضرب وزن‌ها در ورودی‌ها را محاسبه کرده و در انتها به وسیله یک تابع تبدیل غیرخطی که به آن تابع فعال‌سازی^{۱۱} نیز می‌گویند نتیجه‌ای را ارائه می‌دهد و خروجی گره را مشخص می‌کند.

۶-۴- تنظیم ابرپارامترها^{۱۲}

ابرپارامترها چگونگی کارکرد شبکه‌ی عصبی و دقت و درستی آن را مشخص می‌کنند. با انتخاب ابرپارامترهای مناسب، می‌توان نتایج بهتری از شبکه‌ی عصبی بدست آورد. این پارامترها باید قبل از تمرین دادن شبکه‌ی عصبی مشخص شوند. ابرپارامترهایی که در این پژوهش باید مشخص شوند در زیر آمده است:

¹ Keras

² Graphic Processing Unit

³ Central Processing Unit

⁴ Data augmentation

⁵ Flip

⁶ Rotate

⁷ Scale

⁸ Contrast

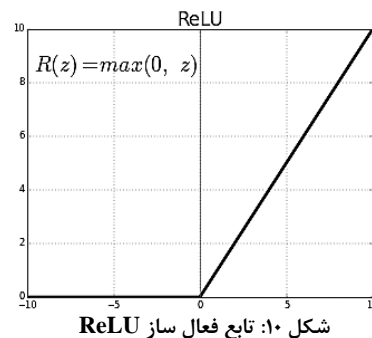
⁹ Luminance

¹⁰ Bias

¹¹ Activation Function

¹² Hyperparameters

- تعداد لایه‌های شبکه: تعداد لایه‌ها باید با دقت زیادی انتخاب شود. تعداد لایه‌ی زیاد می‌تواند باعث مشکلاتی نظیر بیش‌برازش^۱ و محو شدن gradient شود. لایه کم منجر به داشتن سوگیری بالا و پتانسیل کم مدل خواهد شد.
- تابع فعال‌سازی: انتخاب تابع فعال‌سازی مناسب، یک فرآیند آزمون و خطا است که در آن، باید مجموعه‌ای از توابع متفاوت را امتحان کرد و بهترین تابع را برای مسأله مورد نظر انتخاب کنیم. در این پژوهش از تابع فعال‌سازی ReLU که در شکل ۱۰ نشان داده شده برای شروع استفاده می‌شود.



- نرخ یادگیری^۲: نرخ یادگیری بیانگر سرعت (گام) بروزرسانی وزن‌ها است که می‌تواند مقداری ثابت باشد یا به‌طور سازگار تغییر کند.
- فیلتر: یک ماتریس از وزن‌ها است که با ماتریس ورودی convolve می‌شود. با فیلترها می‌توان ویژگی‌های مورد نیاز را از تصویر استخراج کرد.
- اندازه حاشیه^۳: با اضافه کردن حاشیه به ماتریس ویژگی، اندازه ماتریس بعد از اعمال کانولوشن حفظ می‌شود که برای نگه‌داشتن اطلاعات حاشیه تصویر مفید است.
- اندازه گام^۴: تعداد پیکسل‌هایی است که در هر جابه‌جایی افقی یا عمودی بر روی ماتریس ورودی و در حین کانولوشن از آن‌ها صرف‌نظر می‌کنیم. از این عمل برای کاهش اندازه ماتریس ورودی استفاده می‌شود.
- تعداد کانال‌ها: تعداد کانال‌ها برابر با تعداد کانال‌های رنگی تصویر ورودی است. اما در لایه‌های بعدی، کانال‌ها تعداد فیلترهایی است که برای عمل کانولوشن استفاده می‌شوند.

۷- شیوه ارزیابی و خروجی طرح

برای ارزیابی نتایج حاصل شده از دقت، صحت، بازیابی و حساسیت به همراه معیار F1 که براساس روابط ۱ الی ۵ و طبق ماتریس آشفتگی^۵ ارائه شده در جدول ۱ تعریف می‌شوند، استفاده می‌شود.

جدول ۱: ماتریس آشفتگی

	<i>Predicted Positives</i>	<i>Predicted Negatives</i>
<i>Positives</i>	True Positives	False Negatives
<i>Negatives</i>	False Positives	True Negatives

$$Precision = \frac{True\ Positives}{True\ Positives + False\ Positives}$$

رابطه ۱

¹ over-fitting

² Learning Rate

³ Padding Size

⁴ Stride Size

⁵ Confusion matrix

$$\text{Accuracy} = \frac{\text{True Positives} + \text{True Negatives}}{\text{True Positives} + \text{False Positives} + \text{True Negatives} + \text{False Negatives}} \quad \text{رابطه ۲}$$

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}} \quad \text{رابطه ۳}$$

$$\text{Specificity} = \frac{\text{True Negatives}}{\text{True Negatives} + \text{False Positives}} \quad \text{رابطه ۴}$$

$$\text{F1 score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad \text{رابطه ۵}$$

در این پروژه مجموعه‌ی داده‌ای شامل تصاویر رادیوگرافی دندان که بر اساس وجود یا عدم وجود ضایعه سیستم دنتی جروس برچسب‌گذاری شده‌اند گردآوری می‌شود. خروجی این پروژه بصورت یک سرویس تحت وب و برنامه موبایل برای سیستم عامل‌های اندروید^۱ و iOS در دسترس خواهد بود. این برنامه دارای یک رابط گرافیکی خواهد بود که کاربر با بارگذاری عکس تصویربرداری دندان، نتایج پیش‌پردازش انجام‌شده روی تصویر و خروجی نتیجه‌ی شبکه عصبی عمیق را مشاهده می‌کند.

۸- شرح وظایف به تفکیک

آریا وارسته‌نژاد

- گردآوری مجموعه‌ی داده
- پیش‌پردازش تصاویر
- داده‌افزایی
- جستجوی معماری‌های شبکه عصبی
- آموزش شبکه عصبی
- تحلیل و ارائه نتایج به کمک نرم افزار SPSS

رضا توسلی

- جستجوی معماری‌های شبکه عصبی
- بررسی معماری‌های حاصل از جستجو
- انتخاب معماری مناسب
- آموزش شبکه عصبی
- طراحی و پیاده‌سازی برنامه وب
- طراحی و پیاده‌سازی برنامه موبایل برای سیستم‌عامل‌های iOS و Android

¹ Android

- [۱] "Cysts in children." <https://www.slideshare.net/drroshnimaurya/cysts-in-children> (accessed 1 June, 2020).
- [۲] D. Hameed. "Odontogenic cyst dina patho." <https://www.slideshare.net/dentistdw00/odontogenic-cyst-dina-patho> (accessed 3 May, 2020).
- [۳] V.FORTUNATI. "How does deep learning work in radiology?" <https://www.quantib.com/blog/https://www.quantib.com/blog/how-does-deep-learning-work> (accessed 4 June, 2020).
- [۴] P. Sharma. "A Step-by-Step Introduction to the Basic Object Detection Algorithms." <https://www.analyticsvidhya.com/blog/2018/10/a-step-by-step-introduction-to-the-basic-object-detection-algorithms-part-1> (accessed 5 May, 2020).
- [۵] J. B. Andrew Tao. "DetectNet: Deep Neural Network for Object Detection in DIGITS." <https://devblogs.nvidia.com/detectnet-deep-neural-network-object-detection-digits/> (accessed 2 June, 2020).
- [۶] "اسمینار: یادگیری عمیق (wiki.sbm.ac.ir/index.php) accessed 24, 2020."
- [۷] M. J. P. Stuart C. White, *Oral Radiology Principles and Interpretation*, 6 ed. evolve, 2009.
- [۸] C. Jeong. "What is the most common location for a dentigerous cyst?" <https://blog.studentrdh.com/most-common-location-for-a-dentigerous-cyst-nbdhe/> (accessed 2 June, 2020).
- [۹] J. I. Pranav Rajpurkar*, Kaylie Zhu, Brandon Yang, Hershel Mehta, Tony Duan, Daisy Ding, Aarti Bagul, Curtis Langlotz, Katie Shpanskaya, Matthew P. Lungren, Andrew Y. Ng. "CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning." <https://stanfordmlgroup.github.io/projects/chexnet/> (accessed 10 May, 2020).
- [۱۰] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," in *Advances in neural information processing systems*, 2015, pp. 91-99 .
- [۱۱] J.-H. Lee, D.-H. Kim, S.-N. Jeong, and S.-H. Choi, "Detection and diagnosis of dental caries using a deep learning-based convolutional neural network algorithm," *Journal of dentistry*, vol. 77, pp. 106-111, 2018.
- [۱۲] S. Imangaliyev, M. H. van der Veen, C. M. Volgenant, B. J. Keijser, W. Crielaard, and E. Levin, "Deep learning for classification of dental plaque images," in *International Workshop on Machine Learning, Optimization, and Big Data*, 2016: Springer, pp. 407-410 .
- [۱۳] J.-H. Lee, D.-h. Kim, S.-N. Jeong, and S.-H. Choi, "Diagnosis and prediction of periodontally compromised teeth using a deep learning-based convolutional neural network algorithm," *Journal of periodontal & implant science*, vol. 48, no. 2, pp. 114-123, 2018.